

Capa de Persistencia Correlacionada y Memoria Híbrida

Autor	Tomi Violini
Curso	AI Automation Avanzado — CoderHouse
Proyecto	Agente calificador de leads (PyMEs y concesionarias, La Plata)
Stack	n8n self-hosted (Docker) · Airtable · Google Gemini
Repositorio	github.com/tomiviolini8/AI-Automation-Avanzado-Proyecto-Final

Página 1 · Arquitectura del workflow

El objetivo del hito es erradicar la **amnesia** entre ejecuciones efímeras de n8n mediante una capa de **Memoria de Largo Plazo** persistida en Airtable, correlacionada por un identificador único de sesión (**Session_ID**). El circuito se inserta sobre la arquitectura Manager-Worker del Módulo 2, entre el trigger y el agente, sin rehacer nada previo.




Figura 1 — Lienzo general del Manager con la capa de memoria y summarization.

Arquitectura de la base de datos de memoria

- Correlación:** todo el circuito se aísla por **Session_ID** (clave del Chat Trigger), evitando la amnesia cruzada entre distintos leads.
- Lectura (post-trigger):** nodo **Airtable** → **Search Records** con filtro `{Session_ID} = "{ $json.sessionId }"` y **Always Output Data = ON** (para no cortar el flujo cuando el lead es nuevo). Un nodo **IF** evalúa `$json.id is not empty` para bifurcar nuevo / recurrente.
- Rama nuevo (False):** **Create Record** inicial y limpio (**Session_ID**, Estado del Caso = **NUEVO**, Fecha, `msg_count = 1`). Sin variables vacías ni alertas técnicas del servidor.
- Rama recurrente (True):** se inyectan los datos duros recuperados (`user_name`, Estado del Caso, Resumen Consolidado) en el **System Prompt** del agente, encapsulados con delimitadores rígidos `[INICIO DE CONTEXTO COMPARTIDO] ... [FIN DEL CONTEXTO COMPARTIDO]` como blindaje anti prompt-injection. En paralelo, **Airtable** → **Update** incrementa el contador de mensajes.
- Summarization (limpieza de contexto):** un **IF** se dispara al alcanzar 5 mensajes (`msg_count ≥ 5`) y envía el contexto a un LLM económico (**Gemini Flash**), que devuelve un objeto JSON estructurado. Un **Update Record** idempotente persiste el resumen y resetea `msg_count = 0`. Regla anti-ruido: solo se almacena el resumen analítico e indicadores accionables (prohibido HTML, logs o transcripciones crudas).

Página 2 · Prompt de summarization (modelo económico)

Prompt exacto utilizado en el nodo **Basic LLM Chain** alimentado por **Gemini Flash** (models/gemini-3-flash-preview). Fuerza una salida JSON limpia, sin markdown ni texto adicional, e incorpora la regla anti-ruido de la consigna.

```
Sos un modulo de summarization. Te paso el contexto de una conversacion con un lead. Devuelve EXCLUSIVAMENTE un objeto JSON valido, sin texto adicional, sin explicaciones, sin markdown, sin ```json.

Formato exacto de salida:
{
  "asunto_principal": "string breve",
  "puntos_clave": ["string", "string"],
  "accion_requerida": "string breve"
}

Reglas:
- Resumi solo lo relevante para calificar/atender al lead.
- PROHIBIDO incluir HTML, logs tecnicos o transcripciones crudas.
- Maximo 3 puntos clave.

[INICIO DE CONTEXTO A RESUMIR]
Resumen previo: {{ $('Airtable - Leer Memoria').item.json.fields['Resumen Consolidado'] }}
Ultimo mensaje del usuario: {{ $('Chat Trigger').item.json.chatInput }}
Estado del caso: {{ $('Airtable - Leer Memoria').item.json.fields['Estado del Caso'] }}
[FIN DE CONTEXTO A RESUMIR]
```

Salida verificada (ejemplo real)

El modelo devolvió un JSON limpio, parseable y sin envoltura de markdown, que se persistió en el campo **Resumen Consolidado**:

```
{
  "asunto_principal": "Interes en producto/nivel 'six seven'",
  "puntos_clave": [
    "El usuario solicita expresamente ser 'six seven'",
    "El caso se encuentra en estado NUEVO"
  ],
  "accion_requerida": "Definir perfil del lead y explicar requisitos"
}
```

Página 3 · Esquema de datos — tabla Memoria

Base **Checkpoint1 - Calificacion Leads**. La tabla **Memoria** convive con la tabla **Leads** del negocio (misma base, una sola credencial). Columnas, tipos y rol de cada campo:

Campo	Tipo Airtable	Rol / Metadato
Session_ID	Single line text (campo primario)	Clave de correlacion por sesion. Filtro del Search Records.
user_name	Long text	Nombre del lead. Se recupera e inyecta en el System Prompt.
Estado del Caso	Single select	Estado de la sesion. Opciones: NUEVO, EN_CALIFICACION, RESPUESTA_ENVIADA, FALLBACK_HUMANO, CERRADO.
Resumen Consolidado	Long text	last_summary: objeto JSON del summarizer. Escritura idempotente.
Datos Clave	Long text	Indicadores accionables (rubro, presupuesto, urgencia).
Fecha de Actualizacion	Date (con hora)	Timestamp de ultima escritura. Auditoria e idempotencia.
msg_count	Number (entero)	Contador de mensajes de la sesion. Dispara summarization al llegar a 5; se resetea a 0 tras resumir.

Circuito de persistencia híbrida (resumen)

Lectura → **Filtro de exclusión** (IF nuevo/recurrente) → **Escritura**, vinculado obligatoriamente al Session_ID. El alta de nuevos y el guardado de resumen son operaciones idempotentes que sobrescriben el registro correlacionado, nunca lo duplican.

Taxonomía cerrada de intenciones (Manager): CALIFICAR_LEAD · REDACTAR_RESPUESTA · FALLBACK_HUMANO.