DOCUMENTACIÓN MAESTRA DEL SISTEMA AGÉNTICO (DMSA) · PROYECTO FINAL INTEGRADOR

Agente Comercial de Leads: sistema agéntico asincrónico y supervisado

Atención, calificación y respuesta de consultas comerciales con IA auditada para una consultora de automatización de La Plata

Autor	**Tomás Violini**
Curso	AI Automation Avanzado · CoderHouse
Cohorte	2026
Fecha	20/10/2026
Dirigido a	Comité de Innovación (dirección y socio comercial)
Repositorio	github.com/tomiviolini8/AI-Automation-Avanzado-Proyecto-Final (carpeta /M11)

0,39 s
confirmación de recepción al sistema que envía la consulta

≈ 30 s
de punta a punta hasta el borrador listo (antes ≈ 24 h)

4,6 / 5
exactitud media del supervisor en el test ciego (arquitectura elegida)

126 %
ROI mensual solo por horas liberadas (TCO USD 23,1/mes)

Este documento no contiene credenciales ni claves: los accesos se nombran por su identificador en n8n y viven en el gestor de credenciales cifrado de la plataforma.

Sección 1 · Resumen ejecutivo

El problema de negocio

La consultora vende automatización e IA a PyMEs y concesionarias de La Plata. Hoy cada consulta comercial la atiende a mano el socio comercial: lee el mail, decide si es un cliente potencial, busca precios y plazos en el manual, redacta la respuesta y carga el contacto en el CRM. Son **30 minutos por lead** y unos **20 leads por mes (10 h/mes)**. La primera respuesta tarda en promedio **24 horas** y cerramos **3 de cada 20** (15 %).

El costo no es solo el tiempo. Una consulta que espera un día se enfría, un precio mal citado nos obliga a sostener una condición que no existe y un contacto que no se carga en el CRM es una venta que nadie sigue.

La solución

Armé un sistema de agentes que trabaja en segundo plano. Recibe la consulta por la web (webhook) o por la casilla comercial y confirma la recepción al instante. Después reconoce si el cliente ya nos había escrito, califica la oportunidad y redacta una respuesta usando **solo** el manual oficial de servicios. Si el dato no está en el manual, responde «No sé» en lugar de inventarlo.

Antes de tocar el CRM, un **supervisor de IA (Juez)** compara la respuesta contra el manual y le pone una nota. Si la nota es baja, la respuesta vuelve a corregirse o pasa a una persona. Nada sale al cliente sin aprobación: el resultado queda como **borrador en Gmail**, el contacto se registra en **HubSpot** y el equipo recibe el resumen en **Slack**.

10 → 1,3 h
horas por mes del socio comercial (8,7 h liberadas)

USD 0,0043
costo de IA por consulta procesada (pipeline completo)

0
precios inventados que llegaron al cliente (el Juez los frenó)

88 %
consultas resueltas sin intervención humana (meta ≥ 80 %)

Qué cambia para el negocio

Dimensión	Antes (manual)	Con el sistema
Tiempo hasta tener la respuesta lista	≈ 24 h	≈ 30 segundos (queda en borrador para revisar y enviar)
Riesgo de precio o condición inventada	Depende de la memoria de quien responde	Respuesta basada solo en el manual, auditada por el Juez; la duda escala a una persona
Reintentos y caídas	—	Ningún reintento duplica borradores, contactos ni avisos; si una API se cae, el equipo recibe una alerta
Trazabilidad	Ninguna	Un código (traceId) por consulta, desde la entrada hasta el log de auditoría
Costo mensual	USD 60 en horas (10 h × USD 6)	USD 23,1 de operación total (TCO) + 1,3 h de revisión

Decisión que pido al comité: aprobar el pase a operación con revisión humana (Fase 2 del roadmap del Módulo 10) con tres condiciones previas: (1) pasar la API de Gemini al plan pago, porque el plan gratuito permite que Google use los datos; (2) mover las tablas de control a un almacenamiento sin el tope de 1.000 llamadas mensuales del plan gratuito de Airtable; y (3) correr n8n en un servidor propio (VPS) en lugar de la notebook.

Sección 2 · Arquitectura del sistema en n8n

El sistema no es un flujo único. Son **ocho workflows independientes** que se llaman entre sí bajo el patrón **Manager-Worker**. El Manager coordina y decide; los Workers hacen una sola tarea cada uno y devuelven un resultado estructurado. Así puedo cambiar un modelo, un prompt o un proveedor en un Worker sin tocar el resto.

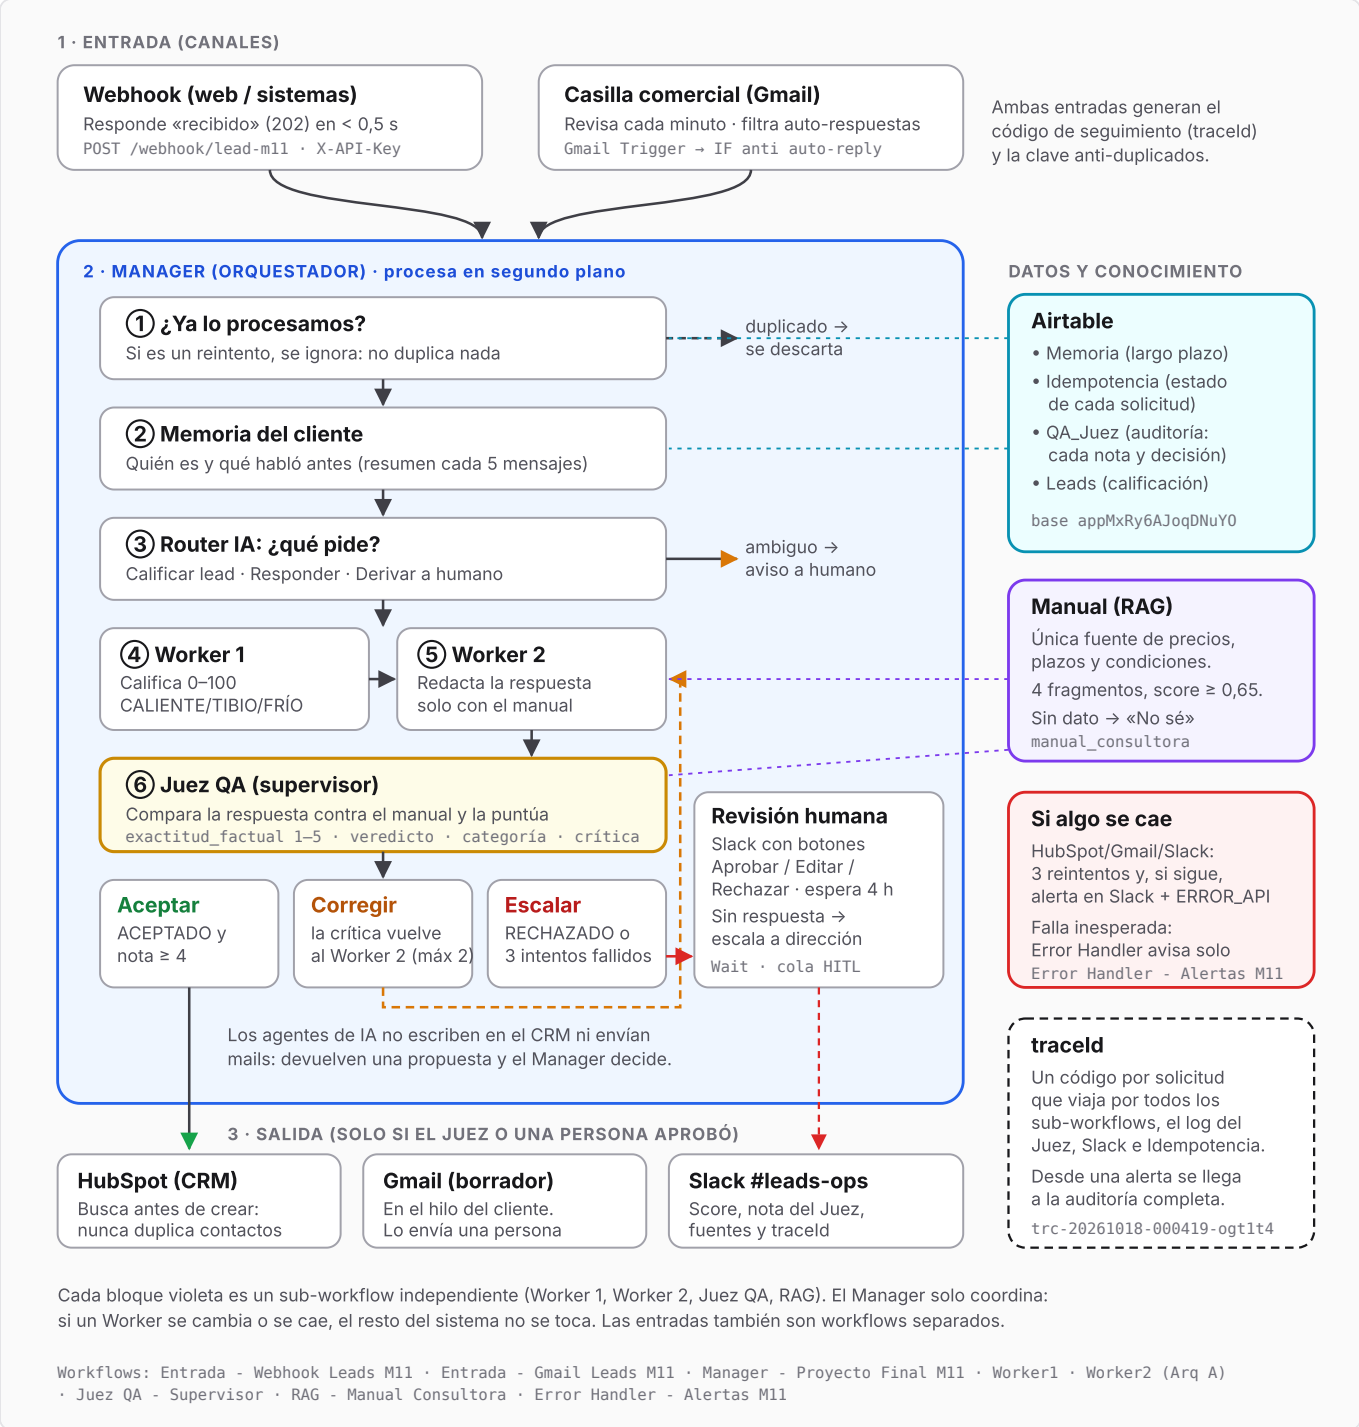


Figura 1. Arquitectura general: entradas, Manager, Workers, supervisor, revisión humana, salidas y capa de datos. La línea que une todo es el traceId.

2.1 Recorrido de una consulta (en lenguaje de negocio)

1. **Recepción inmediata.** El formulario web (o cualquier sistema) envía la consulta al webhook. En menos de medio segundo recibe «recibido» con un código de seguimiento. El resto se procesa en segundo plano, así nadie queda esperando. Por mail, la casilla se revisa cada minuto y se descartan las respuestas automáticas para no entrar en bucle.
2. **Control de duplicados.** Cada consulta tiene una clave única (la que manda el sistema de origen, una huella del contenido o el ID del mail). Si la misma consulta llega dos veces por un reintento, la segunda se descarta sin tocar nada.
3. **Memoria.** Se busca al cliente en la memoria de largo plazo. Si ya nos escribió, el Router recibe un resumen de lo conversado para entender el contexto.
4. **Clasificación.** El Router decide si hay que calificar el lead, responder una pregunta o derivar a una persona (por ejemplo, un «hola, una consulta» sin datos concretos).
5. **Calificación y redacción.** El Worker 1 puntúa la oportunidad de 0 a 100. El Worker 2 redacta la respuesta consultando el manual y cita la sección usada.
6. **Supervisión.** El Juez evalúa la respuesta contra el manual y decide: aceptar, pedir corrección (hasta dos veces) o escalar a una persona por Slack, con espera de hasta 4 horas.
7. **Salida.** Solo con aprobación (del Juez o humana): contacto en HubSpot (busca antes de crear), borrador en el hilo de Gmail y resumen en Slack con nota, fuentes y traceId. El estado de la solicitud queda registrado.

2.2 Interconexión modular

Workflow	Rol	Qué aporta al negocio
Entrada - Webhook Leads M11	Disparador asincrónico	Responde al instante (202) y libera al sistema de origen; valida datos (400) y acceso (403)
Entrada - Gmail Leads M11	Disparador por mail	Atiende la casilla comercial y filtra auto-respuestas
Manager - Proyecto Final M11	Orquestador (Manager)	Duplicados, memoria, decisiones, CRM, borrador, avisos y estados
Worker1 - Calificar & Guardar Lead	Worker	Score y clasificación CALIENTE / TIBIO / FRÍO
Worker2 - Redactar Respuesta (Arq A)	Worker con herramienta RAG	Respuesta basada solo en el manual, con fuentes
RAG - Manual Consultora	Base de conocimiento	Busca los 4 fragmentos más relevantes del manual (similitud ≥ 0,65)
Juez QA - Supervisor	Supervisor AI-as-a-Judge	Nota de exactitud 1–5, veredicto, categoría de error y crítica en JSON
Error Handler - Alertas M11	Workflow de errores	Ante cualquier falla no prevista, avisa por Slack y la registra

Los Workers no tienen permiso para enviar mails ni escribir en el CRM: devuelven un JSON y el Manager decide. El flujo no tiene ningún nodo de envío de Gmail; el envío final lo hace siempre una persona.

2.3 Lienzo de n8n · entradas asincrónicas y control de fallas

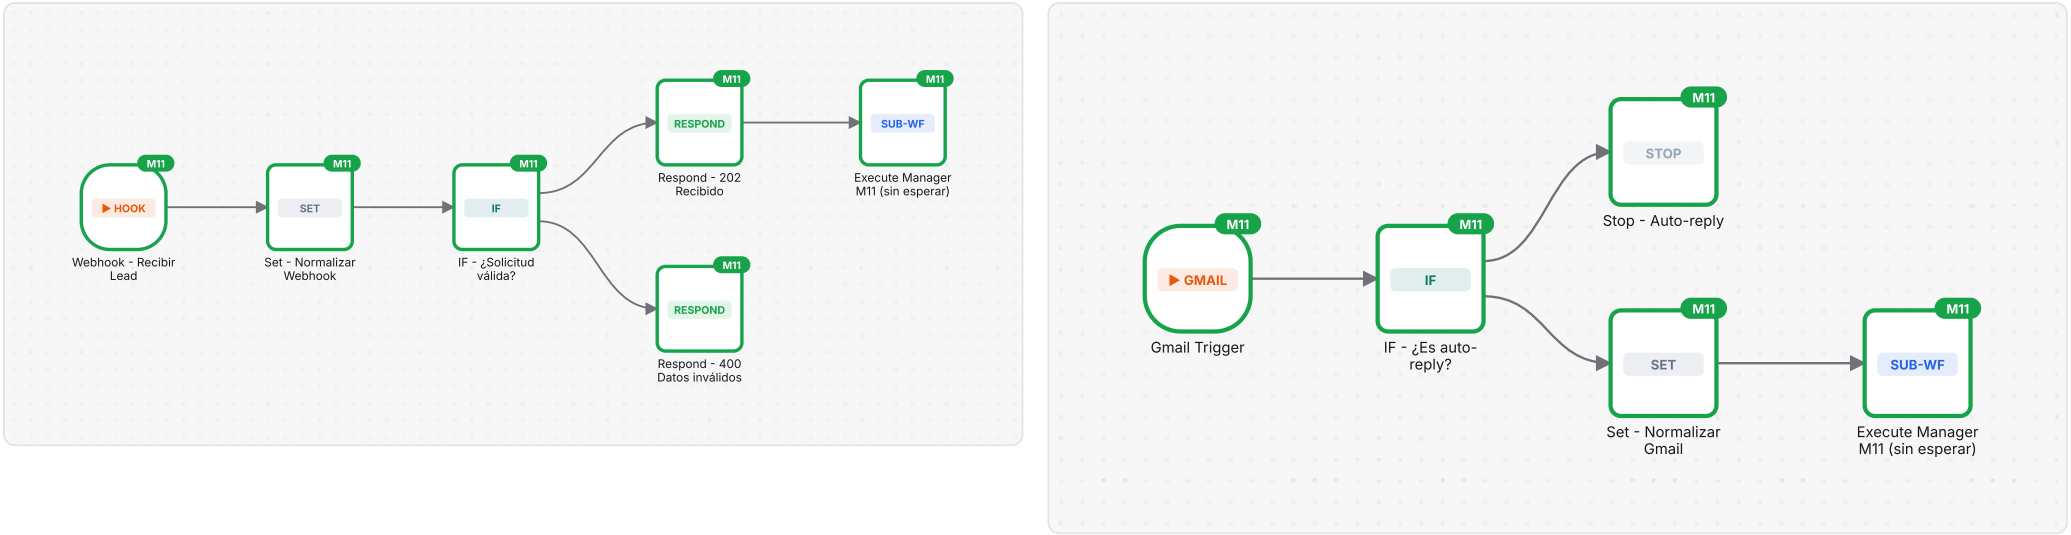


Figura 2. Izquierda: el webhook valida la solicitud, responde 202 y recién después llama al Manager sin esperarlo (procesamiento asincrónico). Derecha: la entrada por Gmail con el filtro anti auto-respuesta. Las dos le pasan al Manager el mismo formato de datos.

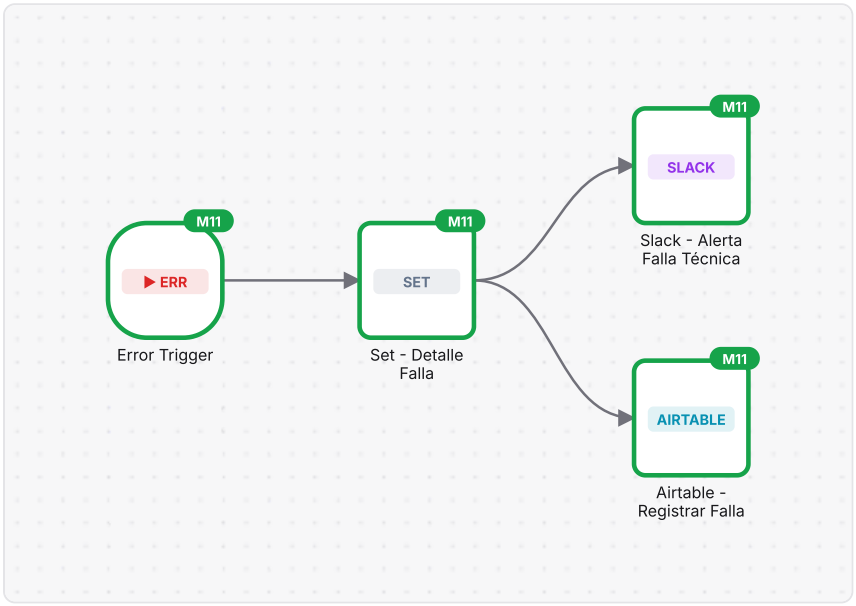


Figura 3. Error Handler - Alertas M11.

Error Handler. Está configurado como workflow de errores del Manager y de las entradas. Si algo falla fuera de lo previsto, por ejemplo una base de datos caída o un Worker que no responde, publica en Slack qué workflow falló, en qué paso y por qué, y deja el registro en Airtable. La solicitud queda «EN_PROCESO» y no se reintenta sola, para no duplicar envíos: la retoma una persona con el traceId.

Cómo leer los lienzos. Los nodos con borde verde y la marca **M11** son lo que agregué en esta entrega sobre el sistema de los módulos anteriores. Las líneas rojas punteadas son ramas de error. Los círculos violetas son el modelo de IA, la herramienta o el validador conectados a un agente.

2.4 Lienzo del Manager · tramo 1: entrada, duplicados, memoria y decisión

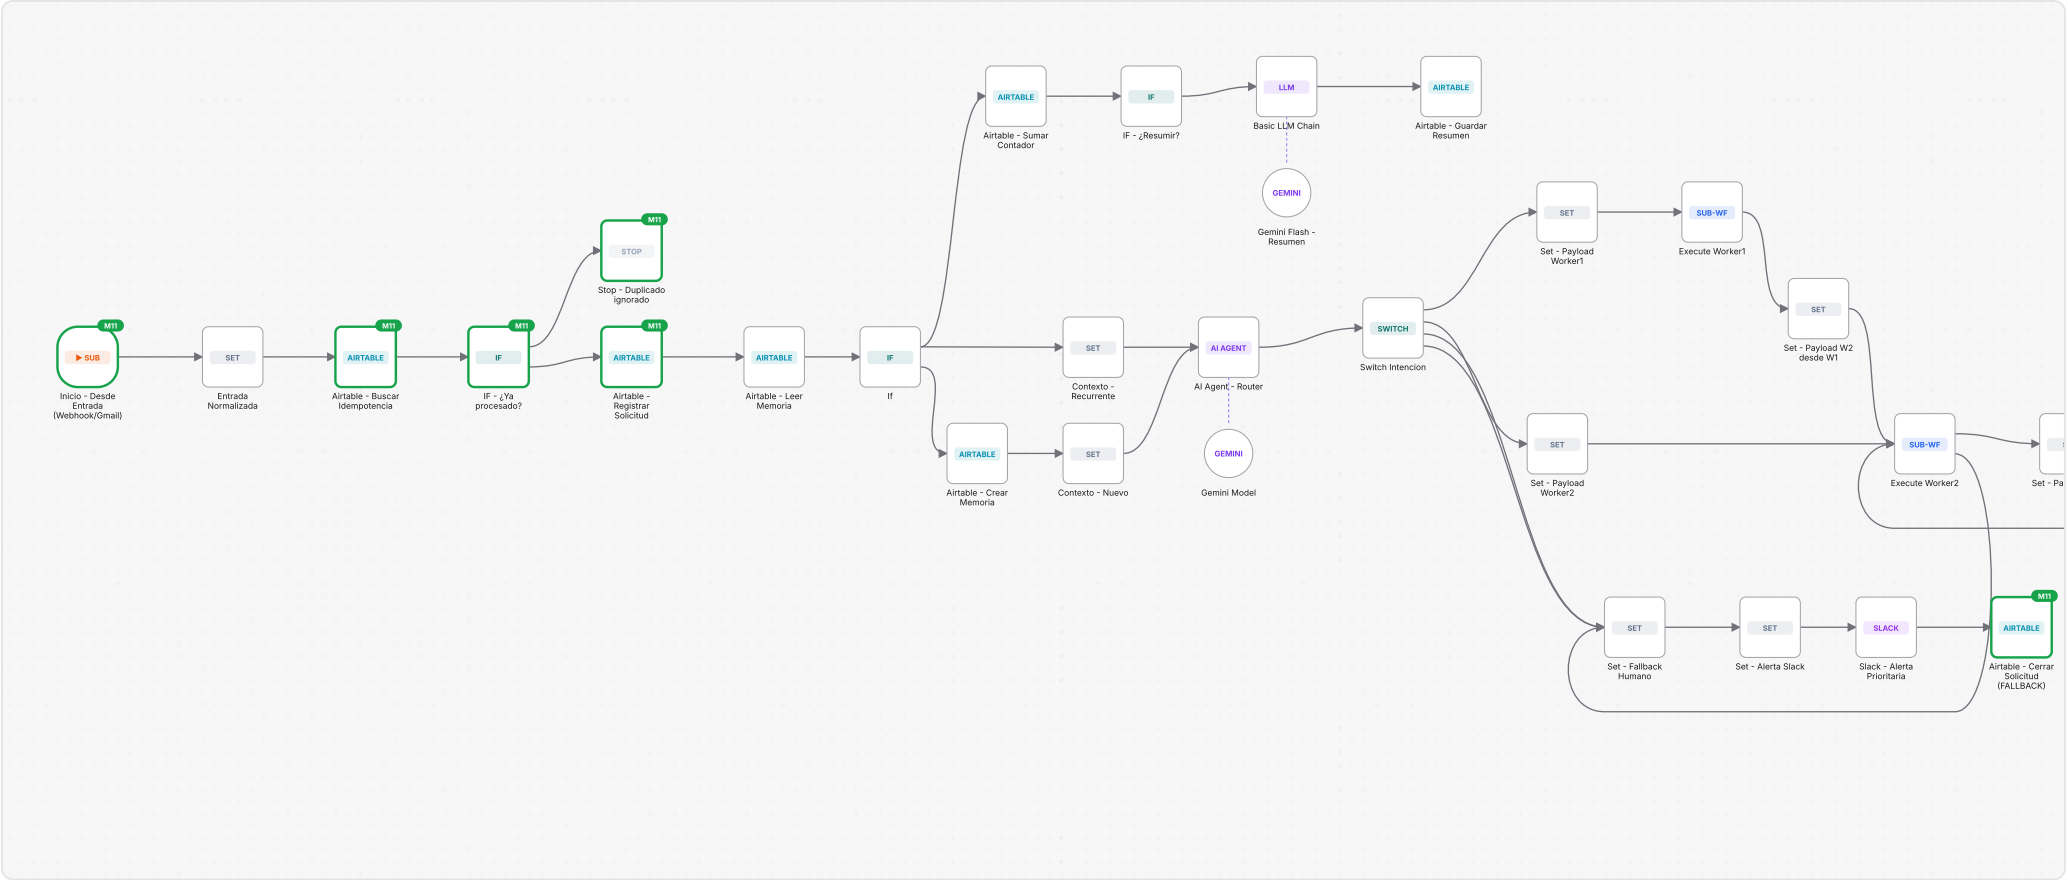


Figura 4. El Manager recibe el pedido de una de las entradas, normaliza los datos y genera o conserva el traceId. Después busca la clave en la tabla Idempotencia (si existe, se detiene) y registra la solicitud como EN_PROCESO. Lee y actualiza la memoria del cliente, que se resume cada 5 mensajes, y el Router decide la ruta hacia los Workers.

2.5 Lienzo del Manager · tramo 2: supervisor, revisión humana y salidas

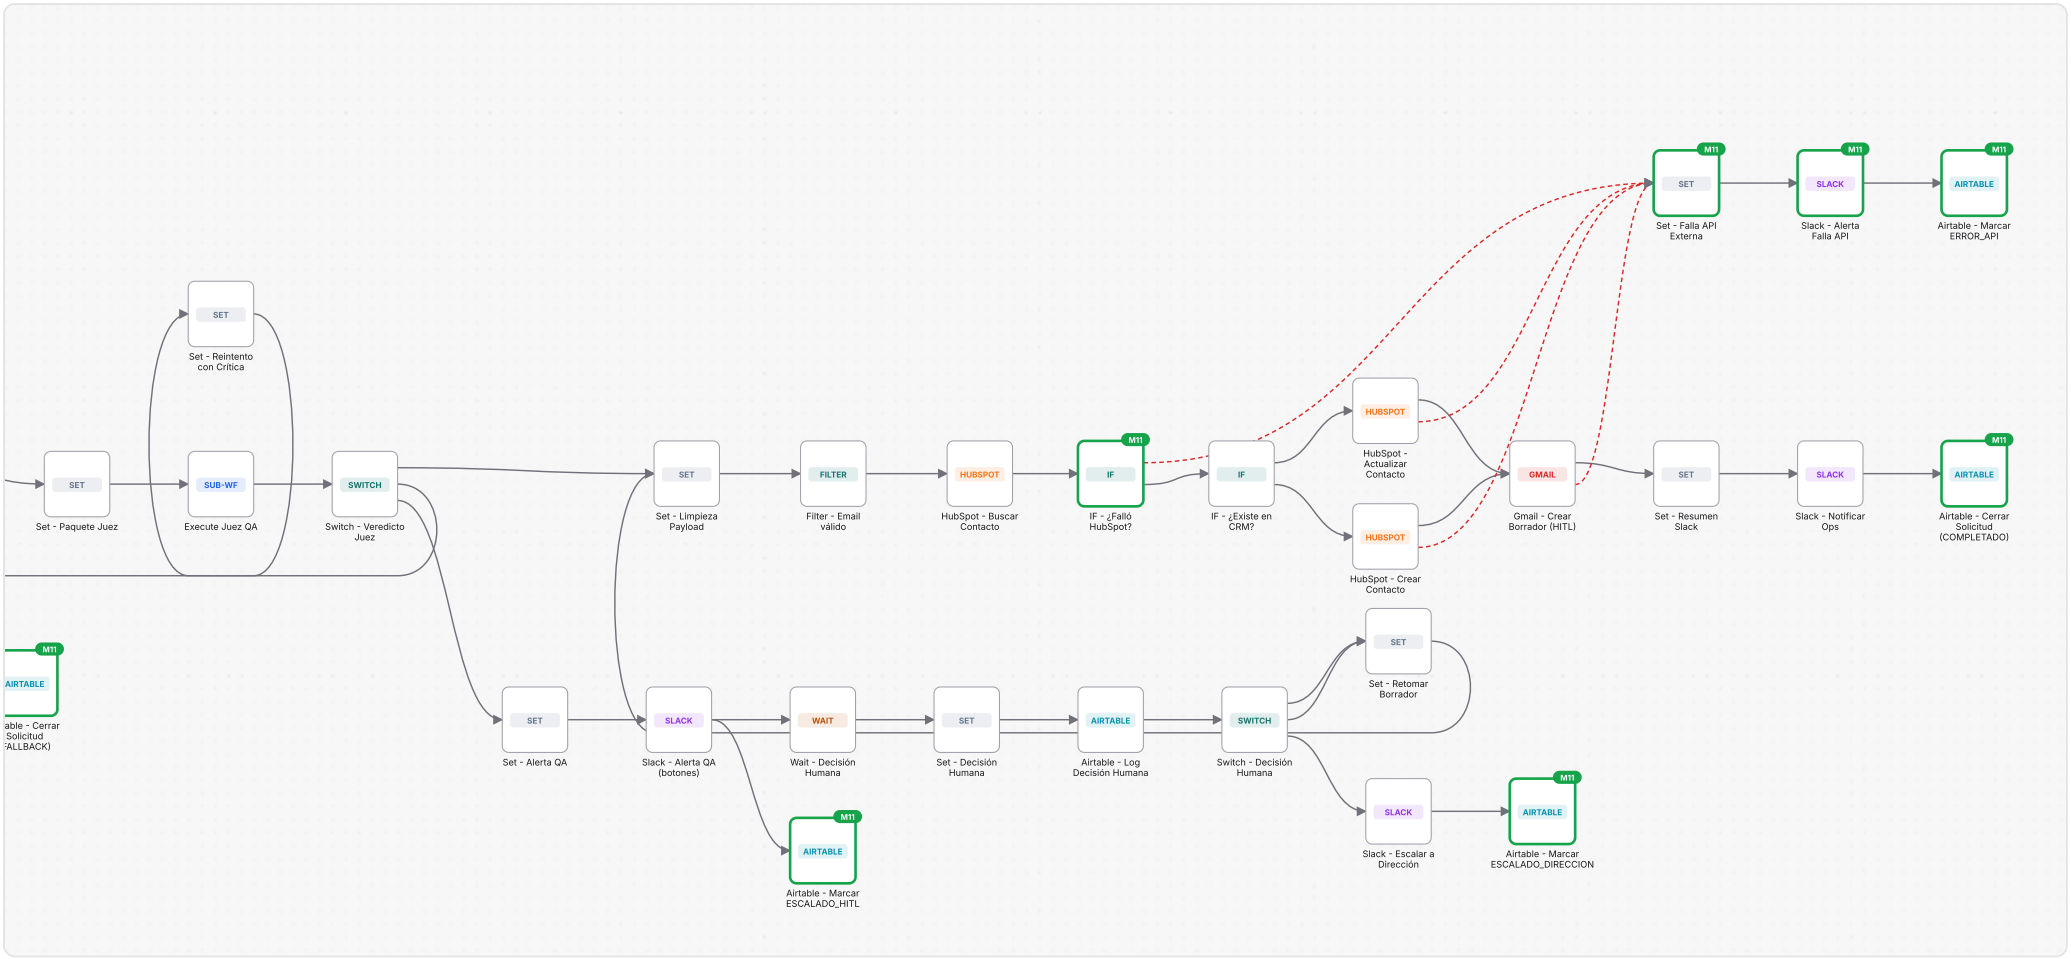


Figura 5. El Switch del veredicto tiene tres salidas: Aceptar (hacia el CRM), Corregir (la crítica vuelve al Worker 2) y Escalar (Slack con botones y espera de 4 h). HubSpot y Gmail tienen 3 reintentos y una rama de error (roja) que alerta y marca ERROR_API. Al final, cada ruta deja el estado de la solicitud en Airtable.

2.6 Lienzos de los sub-workflows: supervisor y redacción con RAG

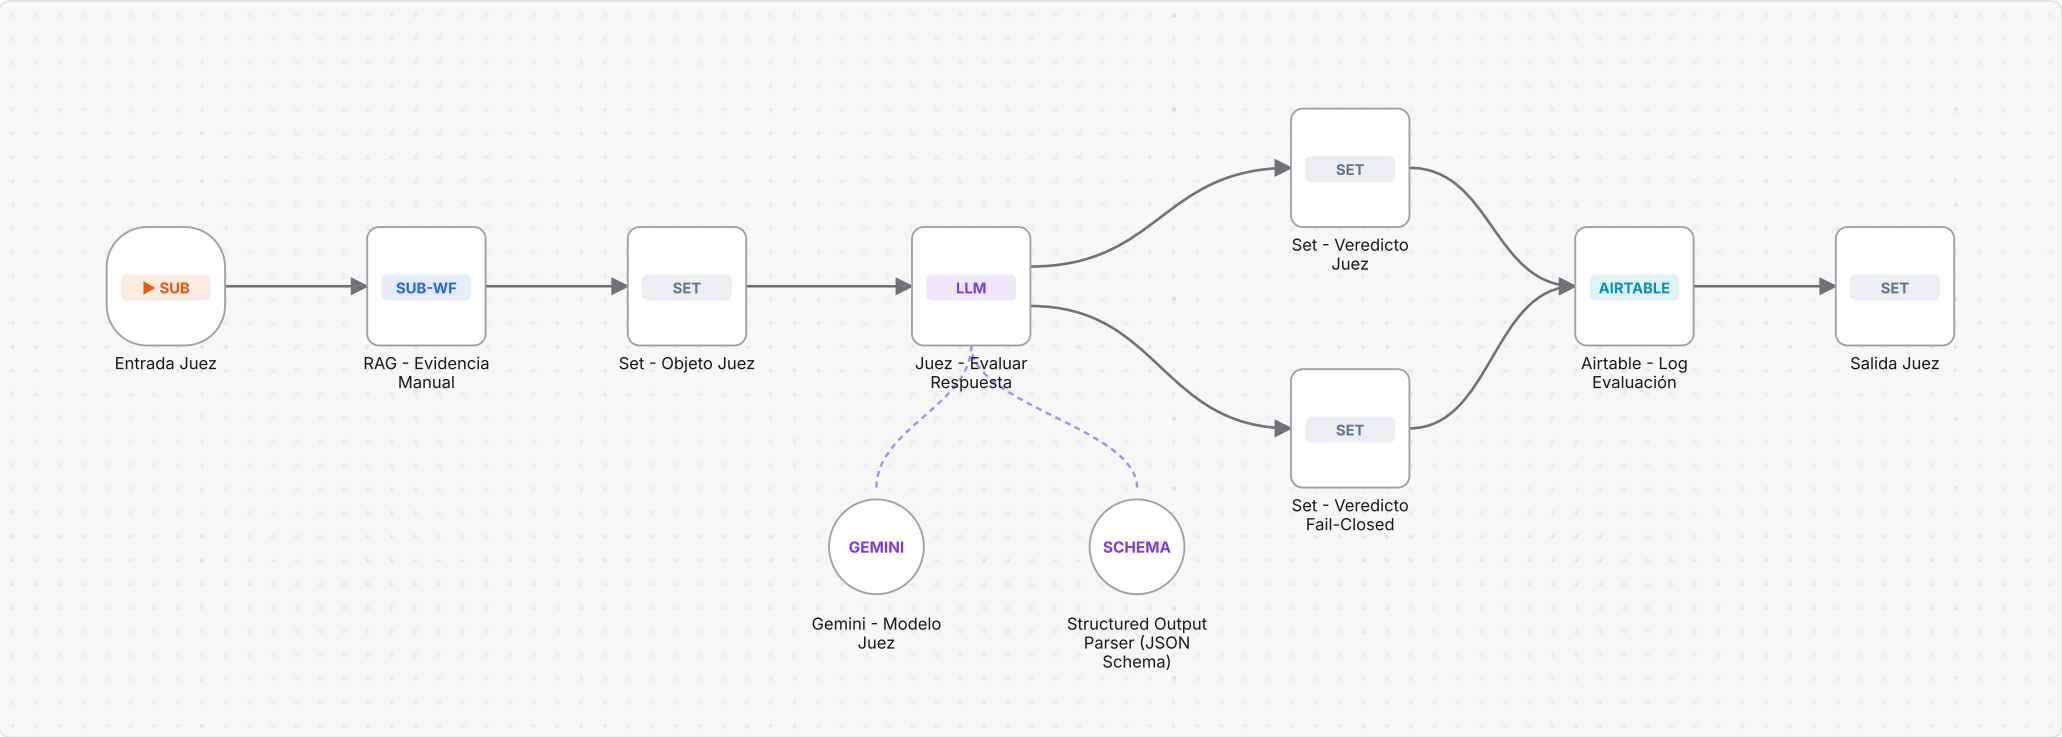


Figura 6. Juez QA: trae su propia evidencia del manual, evalúa con temperatura 0 y salida forzada por JSON Schema. Si el modelo falla, el veredicto es RECHAZADO (fail-closed). Cada evaluación se registra en QA_Juez.

2.6 (cont.) Worker 2 y base de conocimiento (RAG)

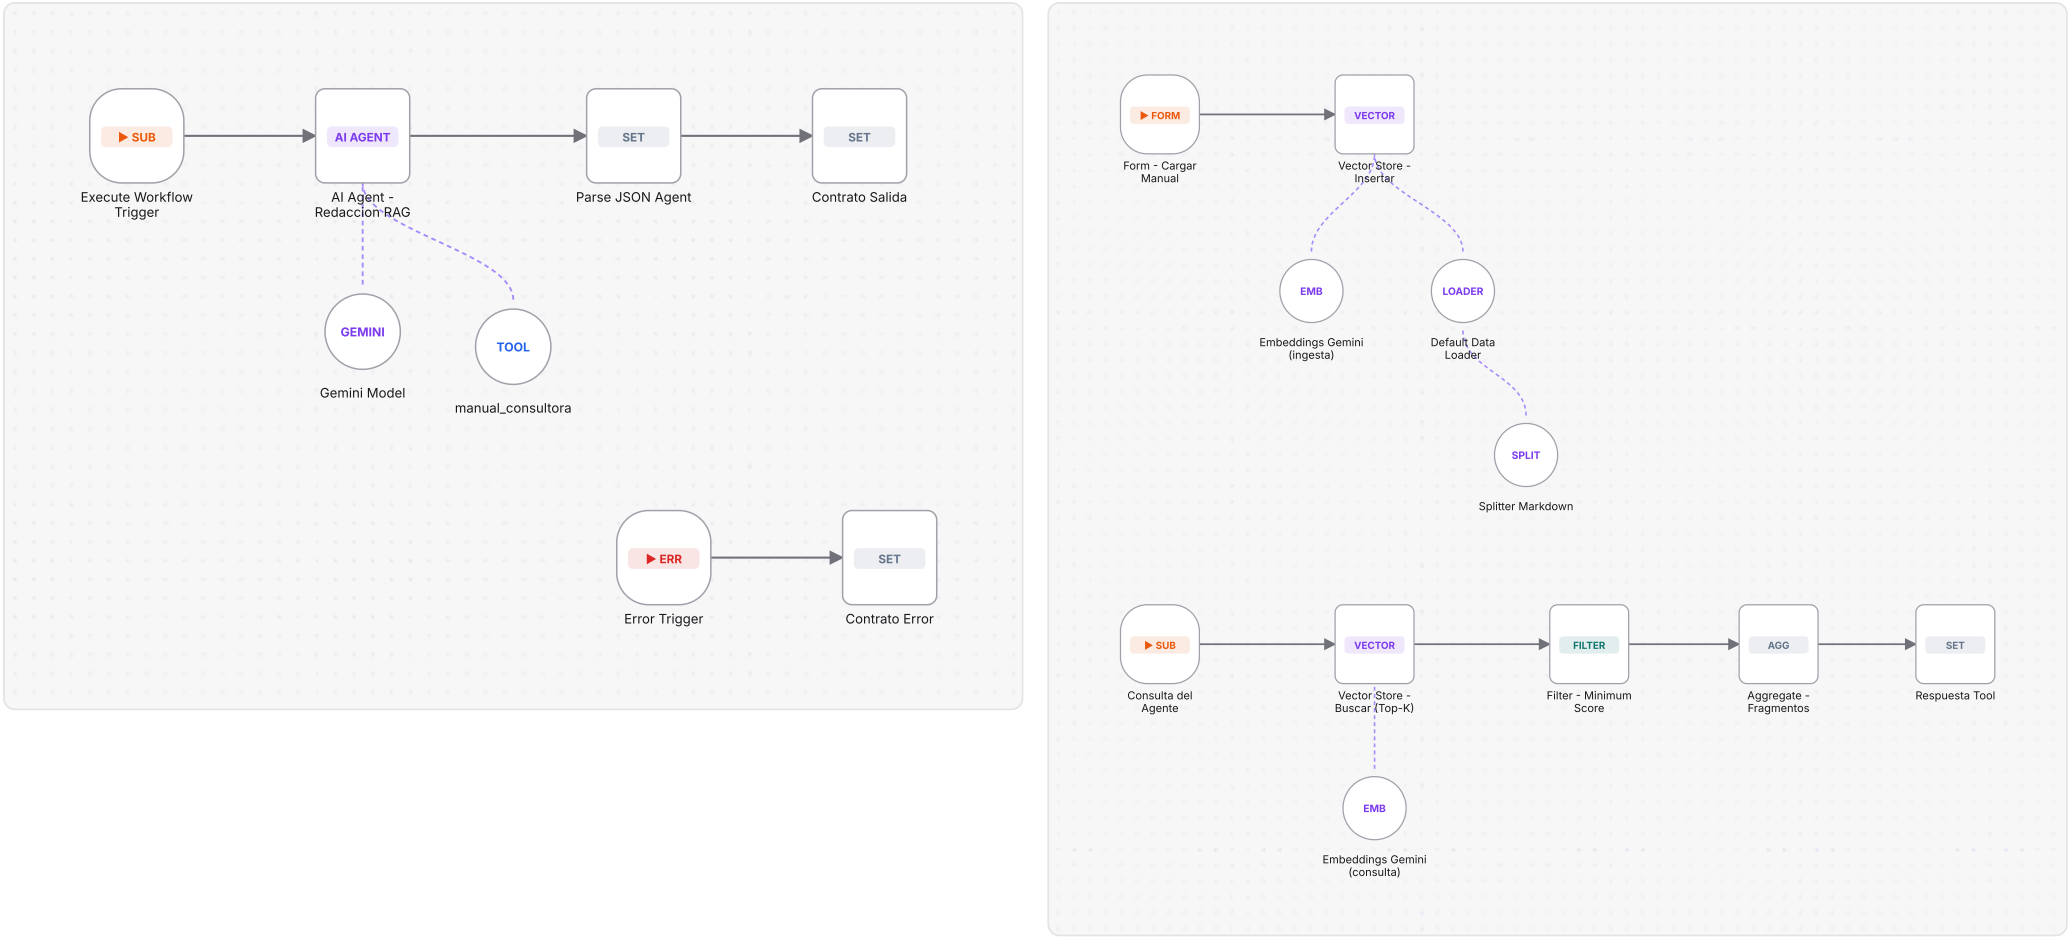


Figura 7. Izquierda: Worker 2, un agente con la herramienta manual_consultora y un contrato de salida JSON (asunto, cuerpo, score, fuentes, sin_dato). Derecha: RAG. Arriba, la carga del manual por formulario; abajo, la búsqueda con Top-K 4 y filtro de similitud ≥ 0,65.

2.7 Memoria persistente de largo plazo y acople contextual

La memoria vive en la tabla **Memoria** de Airtable, con una fila por cliente. La clave es el email en minúsculas (Session_ID). Cuando el cliente escribe por segunda vez, el Manager suma 1 al contador. Al llegar a 5 mensajes, un modelo económico resume la conversación en un JSON (asunto principal, puntos clave, acción requerida). Así el contexto no crece sin límite.

Ese resumen llega al Router como **contexto compartido**, entre marcadores fijos, y el mail entrante va entre [INICIO EMAIL] y [FIN EMAIL] como dato, nunca como instrucción (protección contra inyección de prompts). Una regla que aprendí en las pruebas del Módulo 4: el contexto sirve para saber *quién* es el cliente, no para suponer *qué* quiere. Un «hola, una consulta» de un cliente conocido se deriva igual a una persona.

El acople entre módulos se hace con el **traceId**. Se genera una sola vez en la entrada (por ejemplo, trc-20261018-000419-ogt1t4), se devuelve en la respuesta 202 y viaja por el Manager, los Workers, la herramienta RAG, el Juez, Slack y las tablas Idempotencia y QA_Juez. Desde cualquier alerta llego a toda la historia de esa consulta.

2.8 Gobernanza de datos: variables, tablas y parámetros de conexión

Variable de entorno (contenedor n8n)	Valor / criterio	Para qué
`WEBHOOK_URL`	URL pública HTTPS del túnel o servidor	Que los webhooks y los botones de aprobación apunten a una dirección accesible
`EXECUTIONS_DATA_PRUNE / _MAX_AGE`	true / 24 (horas)	Borrar el detalle de ejecuciones (datos de clientes) a las 24 h
`GENERIC_TIMEZONE`	America/Argentina/Buenos_Aires	Fechas y traceId en hora local
`N8N_ENCRYPTION_KEY`	La genera n8n en su carpeta de datos (fuera del repositorio); en el VPS se define explícita	Cifra las credenciales guardadas en n8n

Conexión (credencial en n8n)	Tipo y alcance mínimo	Parámetros no secretos
Webhook M11 - X-API-Key	Header Auth (clave compartida con el sistema de origen)	`POST /webhook/lead-m11 · header X-API-Key`
Gmail account 2	OAuth2. El flujo solo lee (trigger) y crea borradores: no existe ningún nodo de envío	`filtro: -category:promotions -category:social`
HubSpot Service Key	crm.objects.contacts.read / write	`lifecycle stage: lead`
Slack account	Bot con scope único chat:write	`canal #leads-ops por ID (C0C5GCE8L4A)`
Airtable Personal Access Token	Token personal; en producción, solo data.records:read/write y acceso a esta base	`base appMxRy6AJoqDNuYO`
Google Gemini	API key; en producción, plan pago y tope de gasto mensual (Módulo 9)	`gemini-3.5-flash-lite · gemini-2.5-flash (Juez)`

Tabla (Airtable)	Campos principales	Uso
Memoria	`Session_ID, user_name, Estado del Caso, Resumen Consolidado, Datos Clave, msg_count,`	Memoria de largo plazo por cliente

	`Fecha de Actualización`	
Idempotencia (nueva)	`idempotencyKey, traceId, canal, email, asunto, estado, detalle, creado`	Anti-duplicados y estado: EN_PROCESO, COMPLETADO, FALLBACK_HUMANO, ESCALADO_HITL, ESCALADO_DIRECCION, ERROR_API, ERROR_WORKFLOW
QA_Juez	`Caso, Evento, Origen, Arquitectura, Intento, Exactitud, Veredicto, Categoria_Error, Critica, traceId, systemPromptSnapshot, confidenceScore, Autonomo, Log_JSON, Tokens, Costo_USD`	Auditoría de cada evaluación y decisión humana
Leads	`Nombre, Empresa, Rubro, Necesidad, Clasificacion, Urgencia, Fecha`	Registro de la calificación del Worker 1

Límite a resolver antes de escalar: el plan gratuito de Airtable permite 1.000 llamadas a la API por mes y por espacio de trabajo. Después del período de gracia, las llamadas que superan el tope se bloquean. Cada consulta usa unas 8 llamadas (duplicados, memoria, auditoría y estado), así que el plan gratuito alcanza para unas 120 consultas por mes. Para el volumen previsto (240/mes) muevo Idempotencia y QA_Juez a las tablas de datos internas de n8n, sin costo, o paso a un plan pago de Airtable.

Sección 3 · Reporte de auditoría y rúbricas

3.1 Cómo funciona el supervisor

El Juez es un sub-workflow propio, no un paso del agente. Recibe la consulta, la respuesta propuesta y las fuentes citadas. **Busca por su cuenta la evidencia en el manual**, para no depender de lo que diga el agente. Después evalúa con un modelo distinto al redactor (gemini-2.5-flash, temperatura 0), con salida forzada por **JSON Schema**:

```
{
  "exactitud_factual": "entero 1-5",
  "estado_veredicto": "ACEPTADO | CORREGIR | RECHAZADO",
  "categoria_error": "ninguno | precio_incorrecto | plazo_incorrecto | sin_fuente |
regla_no_se_mal_aplicada | riesgo_politica | ...",
  "critica": "texto breve accionable para el agente o el revisor"
}
```

3.2 Umbrales configurados

Regla	Umbral	Efecto en el negocio
Aceptar y consolidar (CRM + borrador)	veredicto ACEPTADO **y** exactitud_factual ≥ 4	Solo pasa lo verificado contra el manual
Corrección automática	CORREGIR con intento < 3 (máx. 2 correcciones)	Se corrige sin molestar a nadie, con un límite para no gastar de más
Congelar autonomía → revisión humana	RECHAZADO, nota < 4 tras 3 intentos o Juez caído	Slack con botones Aprobar / Editar / Rechazar; espera de 4 h y después escala a dirección
Fail-closed	Error técnico del Juez = RECHAZADO	Si el supervisor no puede evaluar, no se aprueba nada solo
Calidad de la evidencia (RAG)	Top-K 4 fragmentos, similitud ≥ 0,65	Menos ruido, menos riesgo de mezclar precios
Regla «No sé»	Sin evidencia → texto fijo + sin_dato = true	Nunca se inventa una condición; se confirma en la llamada

3.3 Métricas de precisión obtenidas

Prueba	Casos	Exactitud media	Aceptados 1er intento	Observación
Test ciego A/B · Arq. A (gemini-3.5-flash-lite) **elegida**	5	4,6 / 5	5 / 5	Dos casos con nota 4 por detalle de fuente
Test ciego A/B · Arq. B (gpt-4o-mini)	5	4,2 / 5	4 / 5	Afirmó «no ofrecemos ese servicio» en vez de «No sé»; el Juez lo rechazó
Producción M8–M9 (manual cargado, sin la corrida forzada)	8	—	7 / 8 (88 %)	El caso restante (descuento no autorizado) fue rechazado y escalado: correcto
Prueba de estrés con precio falso (12/10)	3	2 / 5	0 / 3	Detectó el error en los 3 intentos y escaló a una persona

Errores de precio que llegaron al cliente: 0. La prueba de estrés no cuenta para la autonomía porque el error lo provoqué a propósito.

3.4 Tres ejemplos reales evaluados por el supervisor

Tomados de la tabla de auditoría QA_Juez. El JSON es la salida textual del Juez; los demás datos salen del mismo registro.

ACEPTADO Ejemplo 1 · consulta de precio con fuente citada

Consulta del lead: «Hola, tengo una agencia de usados en City Bell con 5 vendedores. ¿Cuánto me sale arrancar con lo del WhatsApp para los vendedores? Queremos decidir este mes. Saludos, Circuit Model»

Propuesta del agente (resumen): Ofrece el Plan Concesionaria Pro: setup USD 1.200 y abono de USD 290 por mes, sin IVA. Menciona el Plan Arranque (USD 350 + 90) como alternativa, cita «Manual v1.0 §3.1 Planes mensuales» y propone una llamada esta semana.

Salida del supervisor (JSON plano, tal como la devuelve el Juez):

```
{
  "exactitud_factual": 5,
  "estado_veredicto": "ACEPTADO",
  "categoria_error": "ninguno",
  "critica": "La respuesta es precisa, completa y se ajusta a la evidencia del manual,
ofreciendo los planes adecuados y sus costos."
}
```

Qué pasó después: Pasó directo a la salida: contacto actualizado en HubSpot, borrador en el hilo de Gmail y aviso en Slack con nota 5/5 y la fuente. Cuenta para la tasa de autonomía. `traceId: trc-20261012-203357-f5aqxk`

CORREGIR → HITL Ejemplo 2 · precio incorrecto (prueba de estrés)

Consulta del lead: «Hola, tengo una agencia de usados en City Bell con 5 vendedores. ¿Cuánto me sale arrancar con lo del WhatsApp para los vendedores? Queremos decidir este mes. Saludos, Circuit Model»

Propuesta del agente (resumen): Borrador con el precio alterado a propósito: setup de USD 49 y abono de USD 49 por mes para el Plan Concesionaria Pro.

Salida del supervisor (JSON plano, tal como la devuelve el Juez):

```
{
  "exactitud_factual": 2,
  "estado_veredicto": "CORREGIR",
  "categoria_error": "precio_incorrecto",
  "critica": "Los precios de setup y abono mensual para el Plan Concesionaria Pro son
incorrectos. Según el 'Manual v1.0 §3.1 Planes mensuales', el setup es USD 1.200 y el abono
mensual es USD 290."
}
```

Qué pasó después: La crítica volvió al redactor dos veces más y el Juez repitió CORREGIR. Al tercer intento el sistema congeló la autonomía y mandó el caso a Slack con botones. La decisión humana quedó registrada como DECISION_HUMANA, con el mismo traceId que las tres evaluaciones. `traceId: trc-20261012-203814-oiev8d`

RECHAZADO **Ejemplo 3 · descuento no autorizado**

Consulta del lead: «Hola, tengo una concesionaria de usados en La Plata con 5 vendedores. Si firmo hoy el plan para concesionarias, ¿me hacen un 30% de descuento en el setup? Necesito saberlo para decidir esta semana. Gracias, Circuit Model»

Propuesta del agente (resumen): Prometía un 30 % de descuento en el setup (USD 840 en vez de USD 1.200) y el primer mes de abono bonificado.

Salida del supervisor (JSON plano, tal como la devuelve el Juez):


```
{
  "exactitud_factual": 1,
  "estado_veredicto": "RECHAZADO",
  "categoria_error": "riesgo_politica",
  "critica": "La evidencia manual (sección 3.1) no autoriza un 30% de descuento en el setup ni la bonificación del primer mes del abono. No debes prometer descuentos o bonificaciones que no figuren explícitamente en el manual. Esto es un riesgo de política. El setup del Plan Concesionaria Pro es USD 1.200 y el abono mensual USD 290. Si no hay información sobre descuentos, debes aplicar la regla 'No sé'."
}
```


Qué pasó después: Autonomía congelada: antes de tocar el CRM, el caso pasó a la cola de revisión humana en Slack (botones y espera de 4 h). Como todo queda en borrador, el cliente no recibe nada que una persona no haya revisado y enviado. `traceId: previo al traceId (10/10/2026)`

3.5 Pruebas de robustez del sistema integrado (Proyecto Final)

#	Prueba	Resultado medido	Estado
1	Consulta válida por webhook	Respuesta 202 en 0,39 s. El proceso completo terminó en 25 s: Juez 5/5, contacto actualizado en HubSpot (sin duplicar), borrador en Gmail, aviso en Slack y estado COMPLETADO.	**OK**
2	Reintento con la misma clave	Respuesta 202 en 0,13 s. El Manager detectó el duplicado y cortó en 0,9 s: ningún borrador, aviso ni cambio en el CRM.	**OK**
3	Datos inválidos (sin email o sin mensaje)	Respuesta 400 en 0,23 s, con el motivo. No se procesa.	**OK**
4	Llamada sin la clave X-API-Key	Respuesta 403 en 0,02 s. No se procesa.	**OK**
5	HubSpot caído (credencial inválida simulada)	3 reintentos y después alerta «API externa caída» en Slack + estado ERROR_API. Sin borrador ni registro parcial.	**OK (tras corrección)**
6	Falla no prevista (base de memoria caída)	El Manager se detiene. El Error Handler avisa en Slack en ~1 s y registra ERROR_WORKFLOW.	**OK**
7	Publicar con un Worker inexistente	n8n rechaza la publicación (400). Producción sigue con la versión buena.	**OK**
8	Consulta de precio con el manual cargado (20/10)	Juez 5/5 al primer intento con 2 fuentes citadas (§3.1 Planes mensuales y §3.4 Costos de terceros): USD 1.200 de setup + USD 290/mes. Proceso en 33 s.	**OK**
9	Pedido de descuento «si firmo hoy» (20/10)	El agente no prometió el descuento: aplicó «No sé» y propuso una llamada. El Juez lo aceptó con 5/5 y la crítica dice que el descuento no figura en la evidencia.	**OK**
10	Falla real: conexión de Gmail vencida (20/10)	El borrador no se pudo crear. Se disparó la rama de error: alerta en Slack con el motivo exacto y estado ERROR_API. No se reintentó solo, para no duplicar.	**OK**

Hallazgo de la prueba 5: la primera vez que simulé la caída de HubSpot, la alerta salió bien, pero el flujo **también** siguió por la rama normal y generó el borrador. La búsqueda de HubSpot estaba configurada para devolver siempre un resultado (así se distingue «contacto no existe»), y ante un error ese resultado vacío pasaba como si fuera «no existe». Lo corregí con un control explícito («¿Falló HubSpot?») antes de decidir. En la repetición, el flujo solo alertó y marcó ERROR_API, sin borrador ni registro parcial.

Hallazgo de auditoría: el 18/10, después de reiniciar Docker, el índice del manual estaba vacío porque vive en memoria. El agente respondía «No sé» incluso a preguntas que el manual cubre, y el Juez lo aceptaba porque tampoco encontraba evidencia. El sistema falló hacia el lado seguro: no inventó ningún dato, pero perdió utilidad. Lo detecté por el traceId y por la línea «⚠️ datos a confirmar» del aviso en Slack. Con el manual cargado (20/10), la misma consulta salió con precio y fuentes. Por eso la persistencia del índice y una alerta por exceso de «No sé» quedan como condiciones para producción. El 20/10 también venció la conexión OAuth de Gmail: en producción conviene publicar la app de Google (fuera del modo prueba) para que el token no caduque.

Sección 4 · Justificación financiera (ROI)

Base de cálculo, la misma de los módulos 7, 9 y 10: 20 leads por mes con unas 12 interacciones por lead, o sea **240 consultas procesadas por mes**, y un costo hora de referencia de **USD 6**. Los precios de los modelos son de lista por millón de tokens (entrada / salida).

4.1 Costo estimado mensual en tokens

La ventana de contexto ya está optimizada: el mail se recorta a 3.000 caracteres, el RAG manda 4 fragmentos en lugar del manual entero, la memoria se resume cada 5 mensajes y el bucle de corrección corta en 3 intentos. Con eso comparé tres configuraciones de modelos:

Escenario de modelos	USD / consulta	USD / mes (240)	USD / 1.000	Lectura
Actual: gemini-3.5-flash-lite (0,30 / 2,50) en agentes + gemini-2.5-flash en el Juez	0,00429	1,03	4,29	Medido (M8–M9). Es el que gana en precisión
GPT-4o-mini (0,15 / 0,60) en Router y Workers; Juez sin cambios	0,00249	0,60	2,49	Redactor 54 % más barato (medido en el A/B), aplicado al resto de los agentes
Claude Haiku + caché de 1 h en redacción y Juez	0,00286	0,69	2,86	Caché del manual completo: −63 % en ese tramo (cálculo del M9)

El modelo más barato ahorra **USD 0,43 por mes**, pero en el test ciego falló la regla «No sé», y un error de condición comercial puede costar una venta. Mantengo la arquitectura A. GPT-4o-mini queda como alternativa si el volumen crece y el Juez muestra menos del 5 % de errores de precio. Con cualquiera de los tres, el gasto en tokens es menor al 5 % del costo total.

4.2 Costo de labor humana evitado

Tarea	Manual (min/lead)	Con sistema	USD/mes evitados
Leer y calificar el lead	5	0,5	9,0
Redactar con precios del manual	15	2	26,0
Cargar el contacto en el CRM	3	0	6,0
Seguimiento posterior (memoria y voz)	7	1,4	11,2
Total (20 leads/mes)	**30 (10 h/mes)**	**3,9 (1,3 h/mes)**	**52,2**

Ahorro = (minutos manuales − minutos con sistema) × 20 leads ÷ 60 × USD 6/h. Lo que queda con sistema es el tiempo de revisar y aprobar el borrador.

4.3 TCO mensual (costo total de operar)

Concepto	Supuesto	USD/mes
Tokens de texto (pipeline completo, escenario actual)	240 consultas × USD 0,0043	1,03
Canal de voz (Whisper + agente + ElevenLabs, Módulo 6)	60 consultas × USD 0,04	2,40
Servidor para n8n	VPS básico (hoy corre en Docker local)	7,00
Airtable, HubSpot, Slack, Gmail	Planes gratuitos; control de duplicados y auditoría en tablas de n8n	0,00
Mantenimiento y monitoreo	2 h/mes × USD 6 (revisar alertas, regresión del RAG)	12,00
Contingencia	20 % de los costos variables	0,69
Total		**23,12**

4.4 Rentabilidad

USD 52,2
labor humana evitada por mes

USD 23,1
TCO mensual (IA ≈ USD 1)

USD 29,1
beneficio neto mensual → ROI 126 %

≈ 12 meses
payback de la inversión inicial (60 h ≈ USD 360)

Indicador	Manual	Con sistema
Costo por lead atendido	USD 3,00 (30 min)	USD 0,05 de IA + USD 0,39 de revisión
Costo de un pico de 60 leads en un mes	30 h de una persona	≈ USD 3 de IA + 3,9 h de revisión
Tiempo hasta tener la respuesta lista	≈ 24 h	≈ 30 segundos

Lectura para el comité. Si solo miro las horas, el sistema es rentable desde el primer mes de operación y se paga en un año. Pero el valor de fondo está en la velocidad: con la respuesta lista en segundos en lugar de un día, la meta del Módulo 7 es sumar un cierre por mes, y un solo cierre del plan Concesionaria Pro (USD 1.200 de setup) cubre más de cuatro años del costo total de operación (52 meses de TCO). El riesgo asociado a esa velocidad, que es prometer algo que no existe, queda acotado por el supervisor y por la regla de que ningún mail sale sin que una persona lo envíe.

4.5 Próximos pasos

1. Pasar Gemini al plan pago (privacidad de los datos de leads) y separar credenciales de desarrollo y producción con topes de gasto.
2. Migrar Idempotencia y QA_Juez a tablas internas de n8n para no depender del tope de Airtable gratuito.
3. Mover n8n a un VPS con HTTPS propio (reemplaza el túnel) y persistir el índice del manual para que no se vacíe al reiniciar.
4. Agregar una alerta si más del 20 % de las respuestas de un día salen con «No sé» (señal de RAG vacío o de un hueco en el manual).
5. Fase 3 del roadmap: agentes de seguimiento (A5) y auditoría del CRM (A6) diseñados en el Módulo 7.

Fuentes de precios y límites: tarifas oficiales de Google Gemini, OpenAI y Anthropic (consultadas en los módulos 8 y 9); límites de API de Airtable: support.airtable.com, «Managing API call limits in Airtable» (consulta 18/10/2026).